

Лабораторна робота № 1

Вхідний аналіз набору даних

Тривалість	Оцінка	Середовище	Форма звіту
2 год аудиторно + 3 год самостійно	4 бали	Jupyter Notebook	ноутбук .ipynb + експорт

1. Мета роботи

Скласти уявлення про незнайомий набір даних наявними засобами, звести кілька різних за структурою таблиць в один узгоджений набір і навчитися розпізнавати, коли візуалізація веде до хибного висновку.

Робота виконується до першої лекції. Нічого нового знати не потрібно: усе, що знадобиться, ви вже проходили в попередніх курсах — Jupyter, бібліотека pandas, побудова графіків.

Завдання роботи

- прочитати файл, який ніхто не готував спеціально для навчання, і розібратися, що в ньому лежить;
- виділити окремі таблиці, привести їх до робочого вигляду й побудувати коректні мітки часу;
- скласти паспорт даних і знайти в них значення, яких там бути не може;
- об'єднати таблиці з різним кроком у часі в один набір;
- побудувати п'ять графіків, кожен — як відповідь на конкретне питання;
- порівняти два подання одних і тих самих даних і пояснити, чому висновки різняться.

2. Вихідні дані

Файл 20171129_FINAL_FINAL.xlsx, аркуш Sheet1.

Це реальні спостереження космічної погоди за 28 серпня — 22 вересня 2017 року, зібрані з трьох різних джерел. Файл видається як є: рівно в тому вигляді, у якому його колись вивантажили зі станцій спостереження. Ніхто не приводив його до ладу, і саме в цьому сенс завдання — справжні дані здебільшого надходять саме такими.

Що в ньому лежить, ви маєте з'ясувати самостійно на етапі 1.

3. Порядок виконання

Робота виконується в наданому робочому зошиті ЛР1_завдання_студенту.ipynb. Спершу впишіть прізвище, групу та свій номер за списком — клітинка надрукує ваше індивідуальне завдання, яке відрізняється від завдання сусіда.

Етап	Зміст	Де виконується
1	Що взагалі лежить у файлі	аудиторно
2	Три таблиці в робочому вигляді	аудиторно
3	Паспорт даних	аудиторно
4	Об'єднання таблиць в один набір	аудиторно
5	П'ять графіків — п'ять питань	аудиторно + самостійно
6	Два графіки одних і тих самих даних	самостійно
7	Три спостереження та індивідуальне питання	самостійно
8	Декларація про використання інструментів ШІ	самостійно

Етап 1. Що взагалі лежить у файлі

Спробуйте прочитати аркуш звичайним способом — `pd.read_excel(файл)` — і подивіться на результат. Поясніть, чому він вийшов саме таким.

Далі прочитайте аркуш без заголовка (`header=None`) і порахуйте кількість заповнених клітинок у кожному стовпці. За згустками ненульових значень визначте, скільки в аркуші таблиць і які стовпці займає кожна.

Над кожною таблицею є службові текстові рядки — це опис від тих, хто дані збирав. Виведіть їх і випишіть для кожної таблиці джерело даних та одиниці вимірювання.

Це найкорисніші п'ять хвилин роботи: жодної з цих відомостей у самій таблиці немає, і без них ви не знатимете, у чому вимірюєте.

Етап 2. Три таблиці в робочому вигляді

Виділіть кожну таблицю в окремий `DataFrame`, дайте стовпцям осмислені назви й перетворіть значення на числа.

У кожній таблиці дата й час записані по-різному та розкидані по кількох стовпцях. Зберіть для кожної один стовпець типу `datetime` і обов'язково виведіть найранішу й найпізнішу дату. Усі три таблиці мають лежати в межах серпня–вересня 2017 року — якщо у вас вийшов інший рік, придивіться, як записано рік у тій таблиці.

Етап 3. Паспорт даних

Для кожної таблиці виведіть розмір, типи стовпців, кількість пропусків, кількість повних дублікатів рядків і описові статистики.

Уважно подивіться на рядок `min`. Серед даних є фізичні величини, які не можуть бути від'ємними. Якщо ви бачите там мінус — знайдіть такі значення, порахуйте, скільки їх, і поверніться до службового опису з етапу 1: там написано, що вони означають. Замініть їх на порожні та покажіть, як після цього змінилися середнє й мінімум.

Окреме питання на подумати. Серед стовпців є такі, для яких `describe()` слухняно рахує середнє й стандартне відхилення, хоча ці числа не мають жодного сенсу. Знайдіть їх і поясніть своїми словами, чому. Підказка: не кожне число в таблиці є результатом вимірювання.

Етап 4. Об'єднання таблиць

Таблиці мають різний крок у часі. Щоб працювати з ними разом, потрібна спільна сітка — беремо годину. Кожна таблиця потребує своєї дії:

1. дані з дрібнішим кроком згортаються до години — це `resample` з агрегацією; порахуйте два числа за годину: середнє й максимум;
2. дані з погодинним кроком приєднуються просто по спільній мітці часу;
3. добові дані, навпаки, розтягуються на всі 24 години доби.

Зверніть увагу: таблиці закінчуються не в один і той самий момент, тому результат залежить від типу об'єднання. Спробуйте `inner` і `outer`, подивіться, чим відрізняється кількість рядків, і поясніть свій вибір.

Далі поділіть години на три групи за значенням максимуму потоку $P > 10$ за годину: «тиха» — менше 10, «активна» — від 10 до 1000, «дуже активна» — 1000 і більше. Пороги задані реальною шкалою метеослужби космічної погоди NOAA. Групи потрібні, щоб на етапі 5 було що з чим порівнювати.

Етап 5. П'ять графіків — п'ять питань

Графік будується як відповідь на питання, а не «щоб був». Побудуйте п'ять графіків: розподіл вашого потоку, порівняння швидкості вітру між групами годин, зв'язок двох змінних вашої пари, розподіл годин за групами, зміна потоку в часі.

Вимоги до кожного графіка, без яких він не зараховується:

- підписані обидві осі, з одиницями вимірювання;

- заголовок, який формулює висновок, а не тему — не «Розподіл потоку протонів», а «Середнє перевищує медіану вдванадцятіро»;
- під графіком, у текстовій клітинці, одне речення-твердження про дані. «На графіку видно стовпчики» не зараховується.

Не кожне питання має відповідь «так, зв'язок є». Якщо на графіку нічого не видно — так і напишіть. Відсутність зв'язку — це теж результат, і чесно про неї відзвітувати важливіше, ніж підбирати ракурс, у якому щось наче проглядається.

Якщо гістограма вийде нечитабельною — стовпчик біля нуля і порожньо далі — не залишайте так. Спробуйте побудувати її від логарифма значень і поясніть, що змінилося.

Етап 6. Два графіки одних і тих самих даних

У зошиті наведено готову клітинку, що будує два графіки. Дані в них одні й ті самі, жодне число не змінено. Виконайте її та дайте відповідь на три питання:

1. Який висновок зробить людина, яка бачила тільки перший графік?
2. Який висновок зробить людина, яка бачила тільки другий?
3. Чим ці два графіки відрізняються між собою? Назвіть дві відмінності — вони обидві є в коді.

Потім побудуйте свій графік, який одним зображенням чесно показує, що відбувалося в цьому періоді, і поясніть, чому ви обрали саме такий вигляд.

Етап 7. Три спостереження та ваше питання

Запишіть три спостереження про дані. Спостереження — це твердження, яке спирається на конкретне число або графік з вашого ноутбука. Не «дані цікаві», а, наприклад, «максимальне значення потоку у 2000 разів більше за медіанне, і всі такі години припадають на одні й ті самі три доби». Для кожного вкажіть, де саме у вашій роботі його видно.

Далі дайте відповідь на додаткове питання зі свого варіанта. Відповідь має спиратися на обчислення: наведіть код і результат, а потім сформулюйте висновок словами.

Етап 8. Декларація про використання ШІ

Див. розділ 5.

4. Вимоги до звіту

1. Заповнений файл .ipynb. Ноутбук має виконуватися згори донизу на чистому ядрі: Kernel → Restart & Run All, без помилок. Це перевіряється першою дією на захисті.
2. Файл master_hourly.csv — об'єднана таблиця з етапу 4. Збережіть його до кінця семестру: він знадобиться в лабораторних роботах № 3 і № 4.
3. Експорт ноутбука у HTML або PDF.
4. Заповнена декларація про використання інструментів ШІ.

Правила оформлення. Кожен висновок пишеться в клітинці Markdown, а не в коментарі до коду. Закоментованих чернеток і клітинок без результату у зданій роботі бути не має. Ноутбук — це звіт, а не чернетка: читач має пройти його від початку до кінця й зрозуміти хід міркування без ваших усних пояснень.

У зошиті вбудовано три автоматичні самоперевірки — після етапу 2, після етапу 4 і фінальну. Вони показують, чи не зламався розбір даних, ще до того, як ви почнете будувати графіки. Фінальна клітинка друкує чек-лист готовності роботи.

5. Декларація про використання інструментів ШІ

Користуватися мовними моделями та іншими інструментами штучного інтелекту під час виконання роботи дозволено. Це нормальна інженерна практика, і курс про штучний інтелект не має підстав її забороняти.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок вашого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці. Якщо код згенеровано, але ви його розумієте — робота зарахована. Якщо не розумієте — не зарахована, незалежно від того, хто його написав.

У зошиті для кожного етапу треба обрати одне з формулювань:

- «ні» — інструментами ШІ не користувався;
- «синтаксис» — питав про назву функції або синтаксис, код писав сам;
- «код, перевірено» — код згенеровано, я його прочитав, перевірів і розумію;
- «текст, перероблено» — згенеровано чернетку тексту, яку я переписав по суті;
- «текст, як є» — згенерований текст залишено майже без змін.

Останній варіант не заборонений, але прямо впливає на оцінку: бали ставляться за висновки, а не за наявність абзацу.

Без заповненої декларації фінальна самоперевірка в зошиті не проходить, і робота до захисту не приймається.

6. Критерії оцінювання

Бали	Що досягнуто
0	Дані не опрацьовано, графіки не побудовано або побудовано з грубими помилками.
1	Таблиці прочитано й кілька графіків побудовано, але типи графіків не відповідають типу даних, значень, яких не може бути, не помічено.
2	Таблиці розібрано й об'єднано, графіки коректні та підписані, але висновків під ними немає або вони мають формальний характер.
4	Усе перелічене вище виконано, знайдено й пояснено значення, яких у даних бути не може, під кожним графіком наведено змістовний висновок про дані.

Головне про оцінку: бали ставляться не за наявність графіка, а за речення під ним. Код, який нічого не пояснює, коштує двох балів з чотирьох.

7. Питання до захисту

1. Що сталося, коли ви прочитали файл звичайним `read_excel()` і чому?
2. Скільки таблиць в аркуші і як ви визначили їхні межі?
3. Де записані одиниці вимірювання? Чому це важливо?
4. Ви знайшли значення, яких бути не може. Що це і як воно впливало на середнє?
5. Для яких стовпців середнє не має сенсу? Поясніть своїми словами.
6. Скільки рядків дало `inner`, скільки `outer` і який варіант ви обрали? Чому?
7. Покажіть рядок, де ви агрегували дані до години. Змініть агрегат на інший і скажіть, як зміниться графік. Тепер запустіть і перевірте.
8. Чим відрізняються два графіки в етапі 6? Який з них ви показали б керівникові?
9. Ноутбук виконується на чистому ядрі?