

**МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ НАЦІОНАЛЬНИЙ
УНІВЕРСИТЕТ «ЛЬВІВСЬКА ПОЛІТЕХНІКА»**

**Інститут ІКНІ
Кафедра СШ**



ЗВІТ
до лабораторної роботи № 3

з дисципліни: «Інтелектуальний аналіз та візуалізація даних»
на тему: «Діагностика шкал вимірювання»

Виконав:
ст. гр. ШІ-32
Михальчук Антон Євгенійович

Прийняла:
асистентка кафедри СШ
Торська Роксана Володимирівна

Лабораторна робота № 3

Діагностика шкал вимірювання

Курс СК26 «Інтелектуальний аналіз та візуалізація даних»

Тривалість: 2 год аудиторно + 3 год самостійно · **Оцінка:** 4 бали **Файли:**

Ковід_дані_навчальні.xlsx , ЛР3_помилковий_аналіз.ipynb

Шкала вимірювання визначає, які операції над змінною взагалі мають сенс. Комп'ютер цього не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має вимірювач.

У цій роботі ви складаєте **паспорт восьми змінних** свого варіанта, показуєте на власних даних, які статистики для них недопустимі, і виправляєте чужий аналіз, де таких помилок десять.

```
In [1]: ПРИЗВИЩЕ_ІМЯ = 'Михальчук Антон'
        ГРУПА        = 'ШІ-32'
        НОМЕР        = 13

        assert ПРИЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР, 'Заповніть три поля вище'
        assert 1 <= НОМЕР <= 30, 'Номер має бути від 1 до 30'
```

```
In [2]: import json
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings('ignore')

pd.set_option('display.max_colwidth', 60)

ВАРІАНТИ = json.load(open('lr3_variants_student.json'))
B = ВАРІАНТИ[НОМЕР - 1]

print('=' * 74)
print(f'ВАРІАНТ {B["варіант"]} · {ПРИЗВИЩЕ_ІМЯ} · {ГРУПА}')
print('=' * 74)
print()
print('Ваші вісім стовпців:')
for i, c in enumerate(B['стовпці'], 1):
    print(f' {i}. {c}')
print()
print('Ваша пара для аналізу зв'язку:', ' та '.join(B['пара']))
print()
print('Ваше додаткове питання:')
print(' ', B['питання'])
```

Ваші вісім стовпців:

1. номер i/x
2. Діагноз
3. ЛН
4. Дата розтину
5. КТ
6. Прокальцитонін
7. БРзаг2
8. МНВ1

Ваша пара для аналізу зв'язку: Перебіг та ступінь КТ

Ваше додаткове питання:

Стовпець «номер/жив» містить числа 1 і 2. Які три різні статистики pandas порахує для нього без жодної скарги – і чому кожна з них безглузда?

```
In [3]: ФАЙЛ = 'Ковід_дані_навчальні.xlsx'
df = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')
МОЇ = B['стовпці']

print('Розмір набору:', df.shape)
df[МОЇ].head(8)
```

Розмір набору: (121, 77)

```
Out[3]:
```

	номер i/ x	Діагноз	ЛН	Дата розтину	КТ	Прокальцитонін	БРзаг2	МНВ1
0	2377/239	Негос дв полісегм пнев 4 кл гр	III- IV	2022-03-11	20- 30%	0.126	17.0	3.10
1	1121/19	Негосп полісегм пневм 4 кл гр	II-III	NaT	30- 35%	NaN	13.6	1.22
2	283/674	Негос полісегм пнев 4 кл гр	II	NaT	70- 80%	NaN	18.7	1.03
3	2372/513	Негос дв полісегм пнев 4 кл гр	III- IV	NaT	0.8	NaN	13.6	1.69
4	1441/671	Негос дв полісегм пнев 4 кл гр	II-III	NaT	NaN	NaN	15.3	1.15
5	2573/354	Негос дв полісегм пнев 4 кл гр	II-III	2021-12-26	30- 40%	NaN	15.3	0.90
6	1762/555	Негос дв полісегм пнев 4 кл гр	II-III	NaT	60- 65%	NaN	15.3	1.09
7	2664/348	Негос дв полісегм пнев 3 кл гр	I	NaT	до 17%	NaN	15.3	0.94

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу вимірювання. Спирайтеся не на тип даних у pandas, а на **зміст величини**: що означають її значення і які порівняння між ними мають сенс.

Нагадування:

Шкала	Ознака
Номінальна	значення можна лише порівняти на рівність
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний
Відношень	є природний нуль, відношення мають сенс
Абсолютна	природні і нуль, і одиниця вимірювання

Окремо позначайте **ідентифікатори** — значення, що не є величиною взагалі (номер історії хвороби, прізвище, телефон).

```
In [4]: # Спершу подивіться, що каже pandas – і не довіряйте йому
df[M0I].info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 8 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   номер i/x             121 non-null   object 
1   Діагноз                121 non-null   str    
2   ЛН                     121 non-null   str    
3   Дата розтину           61 non-null    datetime64[us]
4   КТ                     44 non-null    object 
5   Прокальцитонін        46 non-null    float64
6   БРзаг2                 101 non-null   float64
7   МНВ1                   90 non-null    float64
dtypes: datetime64[us](1), float64(3), object(2), str(2)
memory usage: 7.7+ KB
```

```
In [5]: # Далі – що є всередині насправді
for c in M0I:
    z = df[c].dropna()
    типи = ', '.join(f'{t.__name__}×{n}' for t, n in
z.map(type).value_counts().items())
    print(f'--- {c}')
    print(f'    непорожніх {len(z)} з {len(df)} | унікальних
{z.nunique()} | типи: {типи}')
    print(f'    приклади: {[repr(v) for v in z.unique()[:4]]}')
    print()
```

```

--- номер i/x
непорожніх 121 з 121 | унікальних 119 | типи: int×65, str×56
прикладі: ['2377/239', '1121/19', '283/674', '2372/513']

--- Діагноз
непорожніх 121 з 121 | унікальних 15 | типи: str×121
прикладі: ['Негос дв полісегм пнев 4 кл гр ', 'Негосп полісегм пневм
4 кл гр', 'Негос полісегм пнев 4 кл гр', 'Негос дв полісегм пнев 3 кл
гр ']

--- ЛН
непорожніх 121 з 121 | унікальних 6 | типи: str×121
прикладі: ['III-IV', 'II-III', 'II', 'I']

--- Дата розтину
непорожніх 61 з 121 | унікальних 50 | типи: Timestamp×61
прикладі: ["Timestamp('2022-03-11 00:00:00')", "Timestamp('2021-12-26
00:00:00')", "Timestamp('2021-11-19 00:00:00')", "Timestamp('2022-05-13
00:00:00')"]

--- КТ
непорожніх 44 з 121 | унікальних 26 | типи: float×27, str×17
прикладі: ['20-30%', '30-35%', '70-80%', '0.8']

--- Прокальцитонін
непорожніх 46 з 121 | унікальних 17 | типи: float×46
прикладі: ['np.float64(0.126)', 'np.float64(0.9)', 'np.float64(0.1)',
'np.float64(0.104)']

--- БРзаг2
непорожніх 101 з 121 | унікальних 21 | типи: float×101
прикладі: ['np.float64(17.0)', 'np.float64(13.6)', 'np.float64(18.7)',
'np.float64(15.3)']

--- МНВ1
непорожніх 90 з 121 | унікальних 53 | типи: float×90
прикладі: ['np.float64(3.1)', 'np.float64(1.22)', 'np.float64(1.03)',
'np.float64(1.69)']

```

Заповніть паспорт

Для кожного стовпця вкажіть шкалу та **обґрунтування** — одне речення про те, чому саме ця шкала. Обґрунтування оцінюється, назва шкали сама по собі — ні.

```

In [6]: ПАСПОРТ = {
    'номер i/x': ('ідентифікатор',
                  'Номер історії хвороби лише позначає запис
пацієнта; це не величина, '
                  'тому ні порядок, ні різниці між номерами нічого
не означають. '),
    'Діагноз': ('номінальна',
                 'Назви діагнозів можна лише порівнювати на
рівність; природного порядку '
                 'між ними немає (той самий діагноз записано 15
різними написаннями). '),
    'ЛН': ('порядкова',
           'Ступінь легеневої недостатності I < II < III < IV
має природний порядок, '

```

```

        'але «відстань» між сусідніми ступенями невідома й
        неоднакова.'),
        'Дата розтину': ('інтервальна',
                          'Різниця між датами має сенс (кількість днів), але
        нуль календаря умовний: '
                          'сказати, що одна дата «удвічі більша» за іншу, не
        можна.'),
        'КТ': ('абсолютна',
               'Частка ураження легень за КТ: є природний нуль
        (немає ураження) і природна '
               'одиниця (уся легень), тому 0.6 справді вдвічі
        більше за 0.3.'),
        'Прокальцитонін': ('відношень',
                            'Концентрація в нг/мл має природний нуль (речовини
        немає), тому відношення '
                            'мають сенс: 1.0 нг/мл – у 10 разів більше, ніж
        0.1 нг/мл.'),
        'БРзаг2': ('відношень',
                   'Загальний білірубін (повторний аналіз), мкмоль/л:
        природний нуль і '
                   'довільна одиниця вимірювання, тож «удвічі вищий»
        має сенс.'),
        'МНВ1': ('відношень',
                 'Міжнародне нормалізоване відношення згортання
        крові – неперервна величина '
                 'з природним нулем, тому відношення та відсотки
        змін мають сенс.'),
    }

    for c in MOI:
        ПАСПОРТ.setdefault(c, ('', ''))

    паспорт_df = pd.DataFrame(
        [(c, ПАСПОРТ[c][0], ПАСПОРТ[c][1]) for c in MOI],
        columns=['Стовпець', 'Шкала', 'Обґрунтування'])
    паспорт_df

```

Out[6]:

	Стовпець	Шкала	Обґрунтування
0	номер i/x	ідентифікатор	Номер історії хвороби лише позначає запис пацієнта; це н...
1	Діагноз	номінальна	Назви діагнозів можна лише порівнювати на рівність; прир...
2	ЛН	порядкова	Ступінь легеневої недостатності I < II < III < IV має пр...
3	Дата розтину	інтервальна	Різниця між датами має сенс (кількість днів), але нуль к...
4	КТ	абсолютна	Частка ураження легень за КТ: є природний нуль (немає ур...
5	Прокальцитонін	відношень	Концентрація в нг/мл має природний нуль (речовини немає)...
6	БРзаг2	відношень	Загальний білірубін (повторний аналіз), мкмоль/л: природ...
7	МНВ1	відношень	Міжнародне нормалізоване відношення згортання крові — не...

In [7]:

```

# --- САМОПЕРЕВІРКА 1 ---
ДОПУСТИМИ = {'номінальна', 'порядкова', 'інтервальна', 'відношень',
              'абсолютна', 'ідентифікатор'}

for c in MOI:
    ш, об = ПАСПОРТ[c]
    assert ш.strip().lower() in ДОПУСТИМИ, f'{c}: шкалу «{ш}» не
    розпізнано'
    assert len(об.strip()) >= 25, f'{c}: обґрунтування закоротке'

```

```
print('Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.')
```

Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть **тільки те, що дозволяє його шкала**.

- номінальна та ідентифікатор — мода, частоти
- порядкова — додатково медіана та квантили
- інтервальна — додатково середнє та стандартне відхилення
- відношень і абсолютна — усе, зокрема коефіцієнт варіації

Якщо для стовпця не можна порахувати нічого, крім частот, — так і напишіть.

```
In [8]: ПОРЯДОК_ЛН = ['I', 'I-II', 'II', 'II-III', 'III', 'III-IV'] # порядок
        задаємо вручну, не сортуванням

def частка_KT(v):
    """КТ записано змішано: 0.3, '20-30%', 'до 17%'. Повертає частку 0..1
    (середина діапазону)."""
    if isinstance(v, (int, float)):
        return v / 100 if v > 1 else float(v)
    s = str(v).replace('%', '').replace('до', '').replace(' ', '')
    if not s:
        return np.nan
    межі = [float(x) for x in s.split('-')]
    return sum(межі) / len(межі) / 100

def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = df[стовпець].dropna()
    if стовпець == 'КТ': # спершу приводимо змішані
        записи до частки
        з = з.map(частка_KT).dropna()
    if pd.api.types.is_datetime64_any_dtype(з):
        з = з.dt.date
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()

    if ш in ('ідентифікатор',):
        return р
    # номінальна і вище: мода й частоти
    р['мода'] = з.mode().iloc[0]
    р['частоти (топ-3)'] = {k: int(v) for k, v in
        з.value_counts().head(3).items()}
    if ш == 'номінальна':
        return р
    # порядкова: медіана й квантили за кодами рівнів у заданому вручну
    порядку
    if ш == 'порядкова':
        коди = pd.Categorical(з, categories=ПОРЯДОК_ЛН,
```

```

ordered=True).codes
    q1, med, q3 = np.quantile(коди, [0.25, 0.5, 0.75],
method='nearest')
    p['медіана'] = ПОРЯДОК_ЛН[med]
    p['квартилі'] = (ПОРЯДОК_ЛН[q1], ПОРЯДОК_ЛН[q3])
    return p
    # інтервальна: ще середнє й стандартне відхилення (для дат – у днях);
    KB недопустимий
    if ш == 'інтервальна':
        дати = pd.to_datetime(pd.Series(з))
        p['медіана'] = дати.median().date()
        p['середнє'] = дати.mean().date()
        p['ст. відхилення, днів'] = round(дати.std() /
pd.Timedelta(days=1), 1)
        p['розмах, днів'] = (дати.max() - дати.min()).days
        return p
        # відношень і абсолютна: усе, зокрема коефіцієнт варіації та
        геометричне середнє
        з = з.astype(float)
        p['мода'] = float(p['мода'])
        p.update({'медіана': round(float(з.median()), 3), 'середнє':
round(float(з.mean()), 3),
                'ст. відхилення': round(float(з.std()), 3),
                'коєф. варіації, %': round(float(з.std() / з.mean() * 100),
1),
                'геом. середнє': round(float(np.exp(np.log(з[з >
0])).mean()), 3)})
        return p

for c in МОї:
    print(f'--- {c} ({ПАСПОРТ[c][0]})')
    print(' ', допустима_статистика(с, ПАСПОРТ[c][0]))
    print()

```

```

--- номер i/x (ідентифікатор)
    {'непорожніх': 121, 'унікальних': 119}

--- Діагноз (номінальна)
    {'непорожніх': 121, 'унікальних': 15, 'мода': 'Негосп дв полісегм пнев
4 кл група', 'частоти (топ-3)': {'Негосп дв полісегм пнев 4 кл група': 43,
'НГ дв. Полісег пневмонія 4кл гр.': 19, 'Негосп дв полісегм пнев 3 кл гр':
14}}

--- ЛН (порядкова)
    {'непорожніх': 121, 'унікальних': 6, 'мода': 'II-III', 'частоти
(топ-3)': {'II-III': 59, 'II': 21, 'III': 17}, 'медіана': 'II-III',
'квартилі': ('II', 'II-III')}}

--- Дата розтину (інтервальна)
    {'непорожніх': 61, 'унікальних': 50, 'мода': datetime.date(2022, 6,
7), 'частоти (топ-3)': {datetime.date(2022, 6, 7): 3, datetime.date(2022,
4, 7): 2, datetime.date(2022, 4, 27): 2}, 'медіана': datetime.date(2022,
4, 23), 'середнє': datetime.date(2022, 4, 6), 'ст. відхилення, днів':
72.6, 'розмах, днів': 532}

--- КТ (абсолютна)
    {'непорожніх': 43, 'унікальних': 21, 'мода': 0.3, 'частоти (топ-3)':
{0.3: 7, 0.25: 6, 0.8: 3}, 'медіана': 0.35, 'середнє': 0.425, 'ст.
відхилення': 0.22, 'коэф. варіації, %': 51.7, 'геом. середнє': 0.361}

--- Прокальцитонін (відношень)
    {'непорожніх': 46, 'унікальних': 17, 'мода': 0.1, 'частоти (топ-3)':
{0.1: 30, 0.126: 1, 0.9: 1}, 'медіана': 0.1, 'середнє': 0.753, 'ст.
відхилення': 3.01, 'коэф. варіації, %': 399.8, 'геом. середнє': 0.145}

--- БРзаг2 (відношень)
    {'непорожніх': 101, 'унікальних': 21, 'мода': 15.3, 'частоти (топ-3)':
{15.3: 26, 13.6: 19, 18.7: 17}, 'медіана': 15.3, 'середнє': 16.217, 'ст.
відхилення': 5.537, 'коэф. варіації, %': 34.1, 'геом. середнє': 15.651}

--- МНВ1 (відношень)
    {'непорожніх': 90, 'унікальних': 53, 'мода': 1.03, 'частоти (топ-3)':
{1.03: 4, 1.24: 4, 1.08: 4}, 'медіана': 1.19, 'середнє': 1.334, 'ст.
відхилення': 1.032, 'коэф. варіації, %': 77.4, 'геом. середнє': 1.232}

```

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту.

Знайдіть **щонайменше три** такі числа у своєму наборі: обчисліть їх, а потім поясніть, чому кожне з них безглузде.

```
In [9]: df[M0I].describe(include='all').T
```

Out[9]:

	count	unique	top	freq	mean	min	25%	50%	75%
номер i/x	121.0	119.0	1837.0	2.0	NaN	NaN	NaN	NaN	NaN
Діагноз	121	15	Негосп ДВ полісегм пнев 4 кл група	43	NaN	NaN	NaN	NaN	NaN
ЛН	121	6	II-III	59	NaN	NaN	NaN	NaN	NaN
Дата розтину	61	NaN	NaN	NaN	2022-04-06 13:22:37.377049	2021- 01-06 00:00:00	2022- 03-29 00:00:00	2022- 04-23 00:00:00	2022- 05-07 00:00:00
КТ	44.0	26.0	0.3	6.0	NaN	NaN	NaN	NaN	NaN
Прокальцитонін	46.0	NaN	NaN	NaN	0.752957	0.043	0.1	0.1	0.1205
БРзаг2	101.0	NaN	NaN	NaN	16.216832	7.4	13.6	15.3	18.7
МНВ1	90.0	NaN	NaN	NaN	1.333778	0.8	1.0525	1.19	1.34

In [10]:

```

номери = pd.to_numeric(df['номер i/x'], errors='coerce') # pandas
визьме ті номери, що схожі на числа
лн_коди = pd.Categorical(df['ЛН'], categories=ПОРЯДОК_ЛН,
ordered=True).codes + 1 # I=1 ... III-IV=6
дні = (df['Дата розтину'].dropna() - pd.Timestamp('1970-01-01')).dt.days
# дата як «днів від 1970»

БЕЗГЛУЗДІ = [
    ('номер i/x', 'середнє (65 номерів, схожих на числа)',
    round(float(номери.mean()), 1),
    'Номер історії хвороби — лише мітка запису, а не величина: «середній
номер» нічого не каже ',
    'про пацієнтів і зміниться, якщо реєстратура почне нумерацію з
іншого числа.'),
    ('ЛН', 'середнє кодів ступенів', round(float(лн_коди.mean()), 2),
    'Шкала порядкова: відомо, що II важче за I, але не наскільки.
Кодування 1...6 мовчки припускає ',
    'однакові відстані між ступенями, тож середнє 3.57 («між II-III та
III»?) — артефакт кодування, а не «середній ступінь».'),
    ('Дата розтину', 'коефіцієнт варіації, %', round(float(дні.std() /
дні.mean() * 100), 2),
    'Шкала інтервальна: нуль календаря умовний (1970 у pandas, 1900 в
Excel), тому KB = std/mean ',
    'залежить від вибору нуля і для тих самих дат може бути і 0.38 %
(від 1970), і 15.8 % (від 01.01.2021).'),
]

assert len(БЕЗГЛУЗДІ) >= 3, 'Потрібно щонайменше три приклади'
pd.DataFrame(БЕЗГЛУЗДІ, columns=['Стовпець', 'Статистика', 'Значення',
'Чому безглузде'])

```

Out[10]:

	Стовпець	Статистика	Значення	Чому безглузде
0	номер i/x	середнє (65 номерів, схожих на числа)	1770.10	Номер історії хвороби — лише мітка запису, а не величина...
1	ЛН	середнє кодів ступенів	3.57	Шкала порядкова: відомо, що II важче за I, але не наскіл...
2	Дата розтину	коефіцієнт варіації, %	0.38	Шкала інтервальна: нуль календаря умовний (1970 у pandas...

Етап 4. Міра зв'язку для вашої пари

Для двох змінних вашого варіанта треба оцінити зв'язок. Міру обирає **пара шкал**, а не зручність:

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Обґрунтуйте вибір, обчисліть міру й поясніть результат. Окремо покажіть, **що станеться**, якщо застосувати Пірсона там, де він недопустимий, — і чому отримане число не можна інтерпретувати.

```
In [11]: A, B = B['пара']
print('Ваша пара:', A, 'x', B)
print()
print(f'{A}: шкала —', ПАСПОРТ.get(A, ('не у вашому списку',))[0] or
      '(визначте самостійно)')
print(f'{B}: шкала —', ПАСПОРТ.get(B, ('не у вашому списку',))[0] or
      '(визначте самостійно)')
print()
print(df[[A, B]].head(6).to_string())
```

Ваша пара: Перебіг × ступінь КТ

Перебіг: шкала — не у вашому списку

ступінь КТ: шкала — не у вашому списку

```
Перебіг ступінь КТ
0   важкий   середній
1   важкий   середній
2   важкий   критичний
3   важкий   критичний
4   важкий           NaN
5   важкий   середній
```

```
In [12]: ОБРАНА_МІРА = 'рангова кореляція Спірмена'
ЧОМУ_САМЕ_ВОНА = ('Обидві змінні порядкові: «Перебіг» (серед важ < важкий
< вкрай важкий) і «ступінь КТ» '
                  '(легкий < середній < важкий < вкрай важкий <
критичний) мають порядок, але відстані між рівнями невідомі. '
                  'Спірмен використовує лише ранги, тобто тільки
порядок.')
```

```
assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва поля'

from scipy.stats import spearmanr, pearsonr
```

```
# уніфікуємо написання (у даних: «сердній», «серед ступ», «легка»,
пробіли в кінці)
ЧИСТКА_КТ = {'легка': 'легкий', 'сердній': 'середній', 'серед ступ':
'середній',
             'серед ступеня': 'середній'}
ПОРЯДОК_ПЕРЕБІГ = ['серед важ', 'важкий', 'вкрай важкий']
ПОРЯДОК_КТ = ['легкий', 'середній', 'важкий', 'вкрай важкий',
'критичний'] # «вкрай важкий» – окремий рівень

перебіг = df[A].str.strip()
ступінь = df[B].str.strip().replace(ЧИСТКА_КТ)
пара = pd.DataFrame({
    A: pd.Categorical(перебіг, categories=ПОРЯДОК_ПЕРЕБІГ,
ordered=True).codes,
    B: pd.Categorical(ступінь, categories=ПОРЯДОК_КТ,
ordered=True).codes,
}).replace(-1, np.nan).dropna()

print(pd.crosstab(перебіг, ступінь).reindex(index=ПОРЯДОК_ПЕРЕБІГ,
columns=ПОРЯДОК_КТ, fill_value=0))
rho, p = spearmanr(пара[A], пара[B])
print(f'\nСпірмен: rho = {rho:.3f}, p = {p:.3f}, пар спостережень:
{len(пара)}')
```

ступінь КТ	легкий	середній	важкий	вкрай важкий	критичний
Перебіг					
серед важ	6	10	1	0	0
важкий	1	8	9	3	3
вкрай важкий	0	0	0	1	0

Спірмен: rho = 0.630, p = 0.000, пар спостережень: 42

```
In [13]: # Контрприклад: Пірсон на кодах рівнів. Він вважає коди справжніми
числами з рівними відстанями.
# Закодуємо ті самі рівні двома способами – порядок однаковий, змінюються
лише «відстані».
код_1 = {0: 1, 1: 2, 2: 3, 3: 4, 4: 5} # легкий=1 ... критичний=5
код_2 = {0: 1, 1: 2, 2: 3, 3: 4, 4: 10} # той самий порядок, але
«критичний» далеко
for назва, код in [('коди 1-2-3-4-5 ', код_1), ('коди 1-2-3-4-10',
код_2)]:
    r_p, _ = pearsonr(пара[A], пара[B].map(код))
    r_s, _ = spearmanr(пара[A], пара[B].map(код))
    print(f'{назва}: Пірсон = {r_p:.3f} | Спірмен = {r_s:.3f}')

print('\nПорядок рівнів той самий, але Пірсон змінився – він залежить від
довільно обраних кодів.')
print('Спірмен однаковий: йому важливий лише порядок. Тому число Пірсона
тут не можна інтерпретувати.')
```

коди 1-2-3-4-5 : Пірсон = 0.596 | Спірмен = 0.630

коди 1-2-3-4-10: Пірсон = 0.421 | Спірмен = 0.630

Порядок рівнів той самий, але Пірсон змінився – він залежить від довільно обраних кодів.

Спірмен однаковий: йому важливий лише порядок. Тому число Пірсона тут не можна інтерпретувати.

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із заданим порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей
Відношень	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Для кожного свого стовпця вкажіть спосіб підготовки — і **виконайте його** щонайменше для трьох стовпців різних шкал.

```
In [14]: ПІДГОТОВКА = {
    'номер i/x': 'Не беремо в модель: ідентифікатор не несе інформації, а модель може знайти в номерах випадкову закономірність.',
    'Діагноз': 'Зводимо 15 написань до двох значень (3 чи 4 клінічна група), потім one-hot; порядок категорій не вводимо.',
    'ЛН': 'Цілі коди в порядку, заданому вручну (I=0 ... III-IV=5): автоматичне сортування рядків не розуміє зміст римських цифр.',
    'Дата розтину': 'Не беремо в модель: дата є лише в померлих, тож це витік цільової змінної («спойлер» результату).',
    'КТ': 'Лише переводимо змішані записи («20-30%», 0.3) у частку 0...1; додатково масштабувати не треба.',
    'Прокальцитонін': 'Логарифм: розподіл дуже несиметричний (більшість ≈0.1, викиди 10 і 18.22), логарифм стискає викиди.',
    'БРзаг2': 'Стандартизація (z = (x – середнє) / ст. відхилення): розподіл майже симетричний, середнє ≈ медіані.',
    'МНВ1': 'Логарифм: розподіл несиметричний (медіана 1.19, максимум 10.6), як у прокальцитоніну.',
}
for c in MOI:
    ПІДГОТОВКА.setdefault(c, '')

pd.DataFrame([(c, ПАСПОРТ[c][0], ПІДГОТОВКА[c]) for c in MOI],
              columns=['Стовпець', 'Шкала', 'Як готуємо'])
```

```
Out[14]:
```

	Стовпець	Шкала	Як готуємо
0	номер i/x	ідентифікатор	Не беремо в модель: ідентифікатор не несе інформації, а ...
1	Діагноз	номінальна	Зводимо 15 написань до двох значень (3 чи 4 клінічна гру...
2	ЛН	порядкова	Цілі коди в порядку, заданому вручну (I=0 ... III-IV=5): а...
3	Дата розтину	інтервальна	Не беремо в модель: дата є лише в померлих, тож це витік...
4	КТ	абсолютна	Лише переводимо змішані записи («20-30%», 0.3) у частку ...
5	Прокальцитонін	відношень	Логарифм: розподіл дуже несиметричний (більшість ≈0.1, в...
6	БРзаг2	відношень	Стандартизація (z = (x – середнє) / ст. відхилення): роз...
7	МНВ1	відношень	Логарифм: розподіл несиметричний (медіана 1.19, максимум...

```
In [15]: def стандартизувати(з):
    """z-оцінка; сталий стовпець дав би ділення на нуль і мовчазні NaN –
    зупиняємося явно."""
    if з.std() == 0 or з.nunique() <= 1:
        raise ValueError(f'«{з.name}» – сталий стовпець, стандартизація
        неможлива')
    return (з - з.mean()) / з.std()

# 1) номінальна: Діагноз → дві клінічні групи → one-hot
група = df['Діагноз'].str.extract(r'(\d)\s*кл', expand=False).map({'3':
'3 кл. гр.', '4': '4 кл. гр.'})
діагноз_onehot = pd.get_dummies(група, prefix='Діагноз', dtype=int)
print('Діагноз:', df['Діагноз'].nunique(), 'написань →', група.nunique(),
'групи →', list(діагноз_onehot.columns))

# 2) порядкова: ЛН → цілі коди в заданому вручну порядку
лн_код = pd.Series(pd.Categorical(df['ЛН'].str.strip(),
categories=ПОРЯДОК_ЛН, ordered=True).codes,
index=df.index, name='ЛН_код')
assert (лн_код >= 0).all(), 'є значення ЛН поза заданим порядком'
print('ЛН:', dict(zip(ПОРЯДОК_ЛН, range(len(ПОРЯДОК_ЛН)))))

# 3) відношень: Прокальцитонін і МНВ1 → логарифм; БРзаг2 → стандартизація
assert (df['Прокальцитонін'].dropna() > 0).all() and (df['МНВ1'].dropna()
> 0).all()
пкт_лог = np.log(df['Прокальцитонін'])
мнв_лог = np.log(df['МНВ1'])
бр_z = стандартизувати(df['БРзаг2'])

підготовлено = pd.concat([діагноз_onehot, лн_код,
пкт_лог.rename('ПКТ_лог'),
мнв_лог.rename('МНВ1_лог'),
бр_z.rename('БРзаг2_z')], axis=1)
print()
print(підготовлено.describe().round(2).loc[['count', 'mean', 'std',
'min', 'max']].to_string())
```

Діагноз: 15 написань → 2 групи → ['Діагноз_3 кл. гр.', 'Діагноз_4 кл. гр.']

ЛН: {'I': 0, 'I-II': 1, 'II': 2, 'II-III': 3, 'III': 4, 'III-IV': 5}

	Діагноз_3 кл. гр.	Діагноз_4 кл. гр.	ЛН_код	ПКТ_лог	МНВ1_лог
БРзаг2_z					
count	121.00	121.00	121.00	46.00	90.00
101.00					
mean	0.25	0.75	2.57	-1.93	0.21
-0.00					
std	0.43	0.43	1.20	1.11	0.31
1.00					
min	0.00	0.00	0.00	-3.15	-0.22
-1.59					
max	1.00	1.00	5.00	2.90	2.36
8.00					

Перед нормалізацією обов'язково перевірте варіативність. Стовпець, у якому всі значення однакові, дасть нуль у знаменнику — і мовчазний **NaN** замість помилки.

```
In [16]: for c in MOI:
          z = pd.to_numeric(df[c], errors='coerce').dropna()
          if len(z) and z.nunique() == 1:
              print(f'УВАГА: {c} – сталий стовпець, нормалізація дасть ділення на нуль')
          elif len(z) and z.max() == z.min():
              print(f'УВАГА: {c} – max дорівнює min')
          print('Перевірку варіативності виконано.')
```

Перевірку варіативності виконано.

```
In [17]: # --- САМОПЕРЕВІРКА 2 ---
          assert all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in MOI), \
              'Для кожного стовпця вкажіть спосіб підготовки'
          assert len(БЕЗГЛУЗДІ) >= 3, 'Етап 3 не завершено'
          print('Самоперевірка 2 пройдена.')
```

Самоперевірка 2 пройдена.

Етап 6. Виправлення чужого аналізу

Відкрийте файл `ЛР3_помилковий_аналіз.ipynb`. Це звіт, який виконується без жодної помилки й містить десять хибних місць.

Для кожного з десяти заповніть рядок нижче:

- **розділ** — номер розділу звіту;
- **що не так** — яка шкала порушена або яке припущення хибне;
- **чому число неправильне** — що саме воно означає насправді;
- **як правильно** — коректний варіант або обґрунтована відмова від показника.

```
In [18]: ВИПРАВЛЕННЯ = [
          (1, 'Середнє для номінальної шкали: «помер/жив» = 1/2 – це ярлики, а не кількість.',
            'Значення 1.50 залежить від довільного кодування (з кодами 0/1 чи 1/5 вийшло б інше); ',
            '«пацієнт посередині між смертю й життям» не має змісту.',
            'Частоти й частка: померло 61 з 121 (летальність 50.4 %), вижило 60; мода – «помер».'),
          (2, 'Дані не очищено: «ж»/«жін» і «ч»/«чол» – однакові категорії, записані по-різному.',
            '«4 статі» – артефакт написання, а не властивість вибірки; частки груп (46 % «ж») неправильні.',
            'Уніфікувати написання до «ж»/«ч»: жінок 75 (62 %), чоловіків 46 (38 %).'),
          (3, 'Порядкову шкалу відсортовано за абеткою, а потім усереднено коди; написання не очищено.',
            '«Найлегший – важкий, найважчий – середній» – це абетковий порядок, а не тяжкість; середнє кодів ',
            'порядкової шкали не має змісту навіть за правильного порядку.',
            'Уніфікувати написання, задати порядок вручну (легкий < середній < важкий < вкрай важкий < критичний), ',
            'описати частотами й медіаною.'),
```

```

(4, 'Обчислено на непридатних даних: errors="coerce" мовчки
перетворив текстові записи («70-80%», «до 17%») на NaN.',
'39.6 % пораховано лише по 27 пацієнтах із 43; викинуто переважно
великі значення, тож середнє занижене.',
'Спершу перевести всі записи в частку (середина діапазону) – середнє
42.5 % по 43 пацієнтах.'),
(5, 'Змішані формати запису: одне значення 0.9 – це 90 %, записані
часткою.',
'Мінімум 0.9 % означав би несумісний із життям стан; це значення
тягне середнє 82.05 вниз.',
'Привести 0.9 до 90 перед обчисленням (або описувати медіаною, 84,
яка до нього стійка).'),
(6, 'Коефіцієнт варіації для інтервальної шкали (дати): нуль
календаря умовний.',
'KB = std/mean залежить від вибору нуля (тут 1970 р., ≈20 000 днів),
тому 0.595 % нічого не каже '
'про однорідність потоку госпіталізацій – від іншого нуля вийшли б
десятки відсотків.',
'Описувати розкид дат стандартним відхиленням у днях або розмахом
(допустимі для інтервальної шкали).'),
(7, 'Кореляція Пірсона для двох номінальних змінних (стать × помер/
жив).',
'Пірсон міряє лінійний зв'язок між величинами; у статі й результату
лікування немає ні величини, ні напрямку, '
'тож висновок про «відсутність лінійного зв'язку» не має змісту.',
'Таблиця спряженості,  $\chi^2$  і коефіцієнт Крамера V.'),
(8, 'Нормалізовано всі «числові» стовпці без перевірки шкали й
варіативності.',
'ФЕРИТ2 заповнений лише в одного пацієнта (сталій): max = min,
ділення 0/0 дає мовчазні NaN; '
'«помер/жив» – номінальна цільова змінна, її нормалізація
безглузда.',
'Нормалізувати лише стовпці шкали відношень, перевіривши max ≠ min;
сталі стовпці викинути, ціль не чіпати.'),
(9, 'dropna() викидає рядок за будь-який пропуск, а пропуски в цьому
файлі структурні.',
'Дата розтину порожня в усіх живих, ФЕРИТ2 – у 120 пацієнтів, тож
лишилося 0 рядків: '
'«повністю заповнений набір» насправді порожній.',
'Спершу прибрати стовпці зі змістовними чи масовими пропусками,
потім dropna(subset=[потрібні ознаки]) '
'або заповнити пропуски.'),
(10, 'Витік цільової змінної: дата розтину існує лише в померлих.',
'r = 1.00 означає не «найкращий предиктор», а те, що ознака записана
після смерті; до того ж NaT '
'перетворено на -9.2e18, тож усі живі отримали одне штучне число.',
'Виключити дату розтину (і все, що відоме лише після результату) з
ознак; рейтинг будувати мірою, '
'що відповідає шкалі кожної ознаки.'),
]

assert len(ВИПРАВЛЕННЯ) == 10, f'Знайдено {len(ВИПРАВЛЕННЯ)} помилок із
10'
for p in ВИПРАВЛЕННЯ:
    assert len(p) == 4 and all(str(x).strip() for x in p), 'Заповніть усі
чотири поля'
    assert len(str(p[2])) >= 30 and len(str(p[3])) >= 25, 'Пояснення
закороткі'

```

```
pd.DataFrame(ВИПРАВЛЕННЯ, columns=['Розділ', 'Що не так', 'Чому число  
неправильне', 'Як правильно'])
```

Out[18]:

	Розділ	Що не так	Чому число неправильне	Як правильно
0	1	Середнє для номінальної шкали: «помер/жив» = 1/2 — це яр...	Значення 1.50 залежить від довільного кодування (з кодам...	Частоти й частка: померло 61 з 121 (летальність 50.4 %),...
1	2	Дані не очищено: «ж»/«жін» і «ч»/«чол» — однакові катего...	«4 статі» — артефакт написання, а не властивість вибірки...	Уніфікувати написання до «ж»/«ч»: жінок 75 (62 %), чолов...
2	3	Порядкову шкалу відсортовано за абеткою, а потім усередн...	«Найлегший — важкий, найважчий — середній» — це абеткови...	Уніфікувати написання, задати порядок вручну (легкий < с...
3	4	Обчислено на непридатних даних: errors="coerce" мовчки п...	39.6 % пораховано лише по 27 пацієнтах із 43; викинуто п...	Спершу перевести всі записи в частку (середина діапазону...
4	5	Змішані формати запису: одне значення 0.9 — це 90 %, зап...	Мінімум 0.9 % означав би несумісний із життям стан; це з...	Привести 0.9 до 90 перед обчисленням (або описувати меді...
5	6	Коефіцієнт варіації для інтервальної шкали (дати): нуль ...	KB = std/mean залежить від вибору нуля (тут 1970 р., ≈20...	Описувати розкид дат стандартним відхиленням у днях або ...
6	7	Кореляція Пірсона для двох номінальних змінних (стать × ...	Пірсон міряє лінійний зв'язок між величинами; у статі й ...	Таблиця спряженості, χ^2 і коефіцієнт Крамера V.
7	8	Нормалізовано всі «числові» стовпці без перевірки шкали ...	ФЕРИТ2 заповнений лише в одного пацієнта (сталій): max =...	Нормалізувати лише стовпці шкали відношень, перевіrivши ...
8	9	dropna() викидає рядок за будь-який пропуск, а пропуски ...	Дата розтину порожня в усіх живих, ФЕРИТ2 — у 120 пацієн...	Спершу прибрати стовпці зі змістовними чи масовими пропу...
9	10	Витік цільової змінної: дата розтину існує лише в померлих.	r = 1.00 означає не «найкращий предиктор», а те, що озна...	Виключити дату розтину (і все, що відоме лише після резу...

Виправте щонайменше три помилки в коді

Оберіть три з десяти та покажіть правильне обчислення поруч із неправильним.

In [19]:

```
# Розділ 1: середнє номінальної шкали → частоти
print('РОЗДІЛ 1')
print('  хибно   : середнє «помер/жив» =', round(df['помер/жив'].mean(),
2))
частоти = df['помер/жив'].map({1: 'помер', 2: 'вижив'}).value_counts()
print('  правильно:', частоти.to_dict(), f"→ летальність  
{частоти['помер'] / len(df):.1f}%")

# Розділ 4: coerce викидає текстові записи → спершу переводимо все в частку
print('\nРОЗДІЛ 4')
кт_хибно = pd.to_numeric(df['КТ'], errors='coerce')
кт_правильно = df['КТ'].dropna().map(частка_КТ).dropna()
print(f'  хибно   : середнє {100 * кт_хибно.mean():.1f} % по  
{кт_хибно.count()} пацієнтах')
print(f'  правильно: середнє {100 * кт_правильно.mean():.1f} % по  
{len(кт_правильно)} пацієнтах')
```

```
# Розділ 9: dropna() по всіх стовпцях → лише по потрібних ознаках
print('\nРОЗДІЛ 9')
ознаки = ['Вік', 'ЛН', 'spO2 без дот', 'БРзаг2', 'МНВ1']
print('хибно : df.dropna() → рядків:', len(df.dropna()))
print('правильно: df.dropna(subset=ознаки) → рядків:',
      len(df.dropna(subset=ознаки)), '| ознаки:', ознаки)
```

РОЗДІЛ 1

хибно : середнє «помер/жив» = 1.5
 правильно: {'помер': 61, 'вижив': 60} → летальність 50.4%

РОЗДІЛ 4

хибно : середнє 39.6 % по 27 пацієнтах
 правильно: середнє 42.5 % по 43 пацієнтах

РОЗДІЛ 9

хибно : df.dropna() → рядків: 0
 правильно: df.dropna(subset=ознаки) → рядків: 74 | ознаки: ['Вік', 'ЛН', 'spO2 без дот', 'БРзаг2', 'МНВ1']

Етап 7. Висновки та індивідуальне питання

```
In [20]: ВИСНОВКИ = [
    'КТ записано в трьох форматах (0.3, «20-30%», «до 17%»):',
    pd.to_numeric(errors="coerce") мовчки '
    'відкидає 16 із 43 записів, переважно великі діапазони, і занижує',
    'середнє ураження легень до 39.6 % ',
    'замість 42.5 % після переведення всіх записів у частку.',
    'Дата розтину заповнена рівно в усіх 61 померлого й порожня в усіх 60',
    'живих: пропуск тут не помилка, ',
    'а означає «вижив», тому ця ознака – витік цільової змінної і в',
    'модель прогнозу летальності її брати не можна.',
    'Діагноз має 15 різних написань, але по суті містить лише дві',
    'категорії – пневмонію 4 клінічної групи ',
    '(91 пацієнт) і 3 клінічної групи (30): без уніфікації частоти й one-',
    'hot кодування дали б 15 фіктивних категорій.',
    ]
assert len(ВИСНОВКИ) >= 3 and all(len(в) >= 60 for в in ВИСНОВКИ), \
    'Потрібні три змістовні висновки'
for i, в in enumerate(ВИСНОВКИ, 1):
    print(f'{i}. {в}')
```

1. КТ записано в трьох форматах (0.3, «20-30%», «до 17%»):
 pd.to_numeric(errors="coerce") мовчки відкидає 16 із 43 записів, переважно великі діапазони, і занижує середнє ураження легень до 39.6 % замість 42.5 % після переведення всіх записів у частку.
2. Дата розтину заповнена рівно в усіх 61 померлого й порожня в усіх 60 живих: пропуск тут не помилка, а означає «вижив», тому ця ознака – витік цільової змінної і в модель прогнозу летальності її брати не можна.
3. Діагноз має 15 різних написань, але по суті містить лише дві категорії – пневмонію 4 клінічної групи (91 пацієнт) і 3 клінічної групи (30): без уніфікації частоти й one-hot кодування дали б 15 фіктивних категорій.

```
In [21]: print('ВАШЕ ПИТАННЯ:'); print(B['питання']); print()
ВІДПОВІДЬ = (
    'Стовпець «помер/жив» номінальний: 1 і 2 – лише ярлики категорій
    «помер» і «вижив», їх можна було б '
    'закодувати будь-якими іншими числами чи літерами. Pandas бачить
    числа й без скарги рахує, зокрема:\n'
    '1) середнє (mean = 1.50) – «пацієнт посередині між смертю й життям»
    не має змісту, а з кодами 0/1 '
    'чи 1/5 «середнє» було б іншим;\n'
    '2) стандартне відхилення (std ≈ 0.50) – «розкид результату
    лікування» залежить лише від того, якими '
    'числами закодовано категорії: з кодами 0/1 чи 1/10 він був би іншим
    для тих самих даних;\n'
    '3) мінімум і максимум (min = 1, max = 2) – припускають порядок
    «менше–більше», якого між «помер» і '
    '«вижив» немає: якщо поміняти коди місцями, «мінімум» стане
    «максимумом».\n'
    'Коректно описувати такий стовпець частотами й модою: померло 61 з
    121 (летальність 50.4 %), вижило 60.'
)
assert len(ВІДПОВІДЬ.strip()) >= 200, 'Відповідь має бути розгорнутою
(від 200 символів)'
print(ВІДПОВІДЬ)
```

ВАШЕ ПИТАННЯ:

Стовпець «помер/жив» містить числа 1 і 2. Які три різні статистики pandas порахує для нього без жодної скарги – і чому кожна з них безглузда?

Стовпець «помер/жив» номінальний: 1 і 2 – лише ярлики категорій «помер» і «вижив», їх можна було б закодувати будь-якими іншими числами чи літерами. Pandas бачить числа й без скарги рахує, зокрема:

1) середнє (mean = 1.50) – «пацієнт посередині між смертю й життям» не має змісту, а з кодами 0/1 чи 1/5 «середнє» було б іншим;

2) стандартне відхилення (std ≈ 0.50) – «розкид результату лікування» залежить лише від того, якими числами закодовано категорії: з кодами 0/1 чи 1/10 він був би іншим для тих самих даних;

3) мінімум і максимум (min = 1, max = 2) – припускають порядок «менше–більше», якого між «помер» і «вижив» немає: якщо поміняти коди місцями, «мінімум» стане «максимумом».

Коректно описувати такий стовпець частотами й модою: померло 61 з 121 (летальність 50.4 %), вижило 60.

Етап 8. Декларація про використання інструментів ШІ

Користуватися мовними моделями дозволено. Це нормальна інженерна практика.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме

такий, і внести в нього невелику зміну на місці.

Для кожного етапу оберіть одне з формулювань:

- 'ні' — інструментами ШІ не користувався
- 'синтаксис' — питав про назву функції або синтаксис, код писав сам
- 'код, перевірено' — код згенеровано, я його прочитав, перевірів і розумію
- 'текст, перероблено' — згенеровано чернетку тексту, яку я переписав по суті
- 'текст, як є' — згенерований текст залишено майже без змін

```
In [22]: ДЕКЛАРАЦІЯ = {
    'етап 1 — паспорт змінних':      'код, перевірено',
    'етап 2 — допустимі статистики':  'код, перевірено',
    'етап 3 — безглузді числа':       'код, перевірено',
    'етап 4 — міра зв'язку':          'код, перевірено',
    'етап 5 — підготовка до моделі':  'код, перевірено',
    'етап 6 — виправлення аналізу':   'код, перевірено',
    'етап 7 — висновки й відповідь':  'код, перевірено',
}

ЩО_САМЕ_Я_ПЕРЕВІРИВ = (
    'Інструмент: Claude (Claude Code). Шкали всіх восьми стовпців, вибір
    трьох безглузвих чисел, міру зв'язку '
    '(Спірмен, «вкрай важкий» як окремий рівень), способи підготовки
    кожного стовпця, усі десять помилок звіту '
    'та три висновки я визначив сам у діалозі; ШІ написало код і
    сформулювало тексти пояснень з моїх відповідей. '
    'Перевірів: частоти «помер/жив» і збіг дати розтину з померлими
    (61/61), сталість ФЕРИТ2, 0 рядків після '
    'dropna(), середнє КТ 39.6 % проти 42.5 %, зміну Пірсона при іншому
    кодуванні та незмінність Спірмена.'
)
ПІДТВЕРДЖУЮ = True      # я можу пояснити кожен рядок свого коду
                        # і внести в нього зміни на вимогу під час
                        захисту
```

```
In [23]: # --- ФІНАЛЬНА САМОПЕРЕВІРКА ---
ФОРМУЛЮВАННЯ = {'ні', 'синтаксис', 'код, перевірено', 'текст,
перероблено', 'текст, як є'}

перевірки = {
    'заповнено титульні поля':      bool(ПРИЗВИЩЕ_ІМЯ and ГРУПА and
НОМЕР),
    'етап 1: паспорт із 8 стовпців': all(ПАСПОРТ[c][0] and ПАСПОРТ[c][1]
for c in МОЇ),
    'етап 3: три безглузді числа':   len(БЕЗГЛУЗДІ) >= 3,
    'етап 4: міру обрано й пояснено': bool(ОБРАНА_МІРА and
len(ЧОМУ_САМЕ_ВОНА) >= 40),
    'етап 5: підготовку описано':     all(len(ПІДГОТОВКА[c].strip()) >=
15 for c in МОЇ),
    'етап 6: знайдено 10 помилок':    len(ВИПРАВЛЕННЯ) == 10,
    'етап 7: три висновки':          len(ВИСНОВКИ) >= 3,
    'етап 7: відповідь на питання':  len(ВІДПОВІДЬ.strip()) >= 200,
    'декларацію заповнено':          all(v in ФОРМУЛЮВАННЯ for v in
ДЕКЛАРАЦІЯ.values()),
```

```

    'опис перевірки ≥ 120 символів': len(ЩО_САМЕ_Я_ПЕРЕВІРИВ.strip()) >=
120,
    'підтвердження авторства':      ПІДТВЕРДЖУЮ is True,
}

print('ЧЕК-ЛИСТ ГОТОВНОСТІ')
print('=' * 52)
for назва, ок in перевірки.items():
    print((' ГOTOBO      ' if ок else ' НЕ ГОТОВО ') + назва)
print('=' * 52)

assert all(перевірки.values()), 'Робота не готова до задачі — див. чек-
лист вище'
print()
print(f'Робота варіанта {B["варіант"]} готова до захисту.')
print(f'{{ПРИЗВИЩЕ_ІМЯ}}, {{ГРУПА}}')

```

ЧЕК-ЛИСТ ГОТОВНОСТІ

```

=====
ГОТОВО      заповнено титульні поля
ГОТОВО      етап 1: паспорт із 8 стовпців
ГОТОВО      етап 3: три безглузді числа
ГОТОВО      етап 4: міру обрано й пояснено
ГОТОВО      етап 5: підготовку описано
ГОТОВО      етап 6: знайдено 10 помилок
ГОТОВО      етап 7: три висновки
ГОТОВО      етап 7: відповідь на питання
ГОТОВО      декларацію заповнено
ГОТОВО      опис перевірки ≥ 120 символів
ГОТОВО      підтвердження авторства
=====

```

Робота варіанта 13 готова до захисту.
 Михальчук Антон, ШІ-32

Перед задачею

Виконайте **Kernel** → **Restart & Run All**. Ноутбук має пройти згори донизу без жодної помилки — це перше, що перевіряється на захисті.