

Лабораторна робота № 3

Діагностика шкал вимірювання

Тривалість	Оцінка	Середовище	Форма звіту
2 год аудиторно + 3 год самостійно	4 бали	Jupyter Notebook, Python	ноутбук .ipynb

1. Мета роботи

Навчитися визначати шкалу вимірювання кожної змінної набору даних і на цій підставі вирішувати, які статистики, метрики та способи кодування до неї застосовні, а які — ні.

Шкала — це не властивість типу даних у Python. Це властивість самої величини. Комп'ютер шкали не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має той, хто аналізує.

Завдання роботи

- визначити шкалу вимірювання для восьми змінних свого варіанта та обґрунтувати кожне рішення;
- обчислити для кожної змінної тільки ті статистики, які її шкала допускає;
- знайти у власних даних щонайменше три числа, які pandas рахує охоче, але які не мають змісту;
- обрати коректну міру зв'язку для заданої пари змінних і пояснити, чому інші не підходять;
- визначити спосіб підготовки кожної змінної до моделі відповідно до її шкали;
- знайти та виправити десять помилок у чужому аналітичному звіті.

2. Індивідуальне завдання

Робота виконується в наданому зошиті ЛР3_завдання_студенту.ipynb. Впишіть прізвище, групу та свій номер за списком — клітинка надрукує ваш варіант.

Варіант містить:

- вісім стовпців набору даних — по одному представнику кожної шкали плюс лабораторні показники;
- пару змінних, для яких треба обрати міру зв'язку;
- додаткове питання, відповідь на яке оцінюється окремо.

Набори стовпців у різних варіантів не збігаються, тож числа у вашій роботі будуть іншими, ніж у сусіда.

Вихідні дані

Файл Ковід_дані_навчальні.xlsx, аркуш Лист1 — журнал ковідного відділення, 121 пацієнт, 77 ознак. Той самий набір, який розбирали на лекції. Файл анонімізовано, але всі дефекти введення в ньому збережено без змін.

3. Порядок виконання

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу. Спирайтеся не на тип даних у pandas, а на зміст величини: що означають її значення і які порівняння між ними мають сенс.

Шкала	За якою ознакою впізнати
-------	--------------------------

Номінальна	значення можна порівняти лише на рівність; порядку немає
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний (дати, температура за Цельсієм)
Відношень	є природний нуль, відношення мають сенс («удвічі більше»)
Абсолютна	природні і нуль, і одиниця вимірювання (частка, ККД)
Ідентифікатор	не є величиною взагалі: номер запису, прізвище, телефон

Оцінюється обґрунтування, а не назва шкали. Назву можна вгадати — пояснення «чому саме ця» ні.

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть тільки те, що дозволяє його шкала. Кожна наступна шкала дозволяє все, що попередня, і ще трохи.

Шкала	Що можна обчислювати
Номінальна, ідентифікатор	мода, частоти, χ^2 , коефіцієнт Крамера
Порядкова	+ медіана, квантілі, рангова кореляція Спірмена
Інтервальна	+ середнє, стандартне відхилення, різниці
Відношень, абсолютна	+ відсотки, коефіцієнт варіації, геометричне середнє

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту. Знайдіть щонайменше три такі у своєму наборі, обчисліть їх і поясніть, чому кожне безглузде.

Етап 4. Міра зв'язку

Для пари змінних вашого варіанта оцініть зв'язок. Міру визначає поєднання шкал, а не зручність обчислення.

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Окремо покажіть, що станеться, якщо застосувати Пірсона там, де він недопустимий, і чому отримане число не можна інтерпретувати.

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування. Для кожного стовпця вкажіть спосіб підготовки, а для трьох стовпців різних шкал — виконайте його.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із заданим вручну порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей

Відношень, абсолютна	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Перед нормалізацією обов'язково перевірте варіативність: у сталому стовпці `max` дорівнює `min`, знаменник стає нульовим, і замість помилки ви отримаєте мовчазний `NaN`. Модель впаде пізніше й у зовсім іншому місці.

Етап 6. Виправлення чужого аналізу

Відкрийте файл `ЛР3_помилковий_аналіз.ipynb`. Це звіт, який виконується від початку до кінця без жодної помилки: всі числа в ньому обчислено правильно з арифметичного погляду. І в ньому рівно десять хибних місць.

Помилки бувають двох типів: статистика, недопустима для цієї шкали, і число, обчислене на даних, які до цього не придатні. У звіті є обидва типи.

Для кожної з десяти вкажіть:

- номер розділу звіту;
- яка шкала порушена або яке припущення хибне;
- чому отримане число не означає того, що написано у висновку;
- коректний варіант обчислення — або обґрунтовану відмову від показника.

Для трьох помилок на власний вибір покажіть правильне обчислення поруч із неправильним.

Етап 7. Висновки та індивідуальне питання

Три висновки про ваші дані — не загальні фрази, а твердження про конкретні стовпці вашого варіанта. Плюс розгорнута відповідь на індивідуальне питання.

Етап 8. Декларація про використання інструментів ШІ

Обов'язковий етап із машинною перевіркою: без заповненої декларації фінальна самоперевірка не проходить.

4. Вимоги до звіту

1. Заповнений файл `.ipynb`. Ноутбук має виконуватися згори донизу на чистому ядрі: `Kernel → Restart & Run All`, без помилок. Перевіряється першою дією на захисті.
2. Усі три самоперевірки в зошиті мають бути пройдені.
3. Заповнена декларація про використання інструментів ШІ.

5. Декларація про використання інструментів ШІ

Користуватися мовними моделями та іншими інструментами штучного інтелекту під час виконання роботи дозволено. Це нормальна інженерна практика, і курс про штучний інтелект не має підстав її забороняти.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці. Якщо код згенеровано, але ви його розумієте — робота зарахована. Якщо не розумієте — не зарахована, незалежно від того, хто його написав.

У зошиті для кожного етапу треба обрати одне з формулювань:

- «ні» — інструментами ШІ не користувався;
- «синтаксис» — питав про назву функції або синтаксис, код писав сам;
- «код, перевірено» — код згенеровано, я його прочитав, перевірів і розумію;
- «текст, перероблено» — згенеровано чернетку тексту, яку я переписав по суті;
- «текст, як є» — згенерований текст залишено майже без змін.

Останній варіант не заборонений, але прямо впливає на оцінку: бали ставляться за обґрунтування та висновки, а не за наявність абзацу.

6. Критерії оцінювання

Бали	Що досягнуто
0	Шкали не визначено або визначено помилково для більшості змінних. Робота не зарахована.
2	Шкали визначено для частини змінних, недопустимі для них статистики не виявлено.
3	Шкали визначено правильно та недопустимі статистики названо, але помилковий аналіз не виправлено.
4	Шкали визначено правильно для всіх змінних, виявлено всі недопустимі статистики й метрики, помилковий аналіз виправлено та пояснено причину кожної помилки.

7. Питання до захисту

- Покажіть у своєму паспорті стовпець зі шкалою відношень. Чим він відрізняється від інтервальної? Наведіть операцію, допустиму для одного й недопустиму для іншого.
- Чому для вашої пари змінних ви обрали саме цю міру зв'язку? Що станеться, якщо взяти Пірсона?
- Ви знайшли безглузді числа в `describe()`. Чому `pandas` їх порахував і не поскаржився?
- У розділі 6 помилкового звіту коефіцієнт варіації дорівнює 0.595%. Чому це число нічого не означає?
- Чому `df.dropna()` на цьому файлі залишає нуль рядків? Що треба було зробити замість нього?
- Покажіть рядок, де ви нормалізували числовий стовпець. Що станеться, якщо подати туди сталий стовпець? Змініть код і перевірте.
- Стовпець ЛН записано римськими цифрами. Як ви його впорядкували і чому автоматичне сортування тут ненадійне?
- Ноутбук виконується на чистому ядрі?

Питання 6 і 7 — головні: жива правка власного коду за три хвилини показує авторство надійніше за будь-який детектор.