МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
Національний університет «Львівська політехніка»
Кафедра систем штучного інтелекту

МЕТОДИЧНІ ВКАЗІВКИ

до виконання лабораторної роботи № 4

ВІЗУАЛЬНИЙ АНАЛІЗ ДАНИХ ТА ЧАСОВІ РЯДИ: ТОЙ САМИЙ АНАЛІЗ У ДВОХ СЕРЕДОВИЩАХ

з навчальної дисципліни
«Інтелектуальний аналіз та візуалізація даних»

для студентів спеціальності 122 «Комп'ютерні науки»,
освітня програма «Системи штучного інтелекту»

Львів — 2026

1. Мета роботи

Виконати повний цикл аналізу одного часового ряду у двох середовищах — засобами Python та засобами Orange — і пояснити, чому однаково названі метрики якості прогнозу дають у них різні числа.

Робота оцінюється в 4 бали і складається з двох частин: Частина 1 виконується аудиторно засобами Python, Частина 2 — самостійно засобами Orange.

2. Теоретичні відомості

Матеріал повністю розглянуто на лекції 4. Для самостійного опрацювання користуйтеся розширеним зошитом «Лекція_4_розширений_зошит.ipynb», який містить означення, формули та вісімнадцять питань для самоперевірки. Нижче наведено лише те, що безпосередньо потрібне для виконання.

Сила сезонності

F_S = max(0; 1 − Var(залишок) / Var(сезонна складова + залишок)). Значення нижче 0,3 означає, що сезонної складової фактично немає, і те, що виділив метод STL, є шумом.

Ретроспективна перевірка з рухомим початком

Модель навчається на перших k спостереженнях, прогнозує наступні h, початок зсувається, процедура повторюється. Підсумкова метрика — середнє по всіх фолдах. У цій роботі жорстко задано 7 фолдів по 3 кроки.

Тести стаціонарності

ADF: H_0 — ряд нестаціонарний, тож мале p означає стаціонарність. KPSS: H_0 — ряд стаціонарний, тож мале p означає нестаціонарність. Тести застосовують у парі; їхня суперечність є змістовним результатом, а не помилкою обчислень.

3. Вихідні дані та варіанти

Файл	Зміст
ціни_україна_2014_2017.csv	Роздрібні ціни на 25 товарів по 28 ринках України, щомісяця, 03.2014 – 12.2017
lr4_variants_student.json	Розподіл варіантів; зчитується автоматично службовою клітинкою зошита
ЛР4_завдання_студенту.ipynb	Зошит із формулюваннями 15 завдань; код пишете самостійно
ЛР4_помилковий_аналіз.ipynb	Звіт колеги для рецензування (завдання 9)

Джерело даних — World Food Programme, Global Food Prices Database, ліцензія CC BY-IGO.

Варіант визначається автоматично. На початку зошита впишіть прізвище, групу та свій номер за списком групи й виконайте дві службові клітинки — номер варіанта, ринок і товар буде обчислено й надруковано, а змінні MARKET і GOOD стануть доступними для всього подальшого коду.

Ряд вашого варіанта — це конкретний обласний ринок; національне середнє в завданнях не використовується, оскільки його повністю розібрано на лекції.

Назви ринків у наборі подано чинною українською латиницею згідно з постановою КМУ № 55 від 27.01.2010 (Odesa, Kyiv, Kharkiv, Kherson, Kirovohrad, Khmelnytskyi, Vinnytsia, Sumy, Zakarpattia, Zaporizhzhia).

4. Частина 1. Аналіз засобами Python

Завдання 1–10 сформульовано в зошиті «ЛР4_завдання_студенту.ipynb». Заготовок коду в ньому немає навмисно: ви пишете його самостійно. Нижче — лише ті вимоги, недотримання яких унеможливить виконання Частини 2.

Жорстко задані параметри

Параметр	Значення	Чому саме таке
Часова сітка	03.2014 – 12.2017, крок 1 місяць	46 точок; саме стільки має бути після заповнення пропуску
Кількість фолдів	7	Стільки ж задається в Orange; інакше числа двох середовищ незіставні
Горизонт прогнозу	3 місяці	Те саме
Порядок ARIMA	(1, 1, 1)	Orange відтворюватиме саме цю модель
Формат експорту	стовпці date (РРРР-ММ-ДД) і price	Orange має розпізнати date як тип time

Порядок ретроспективної перевірки

Щоб фолди збіглися з Orange, відлічуйте їх від кінця ряду: для фолду f навчальна частина — це всі спостереження до позиції $-3 \cdot f$, а перевіряються наступні 3. При f від 1 до 7 перевіреними виявляться останні 21 місяць ряду.

5. Частина 2. Відтворення аналізу засобами Orange

Потрібен додаток Timeseries. Встановлення: Options → Add-ons… → знайти Orange3-Timeseries → встановити → перезапустити Orange. Після цього в лівій панелі з'явиться категорія Time Series.

Крок 1. Завантаження ряду

- Віджет File. Відкрийте збережений у завданні 10 файл «ряд_для_orange.csv».
- Перевірте в таблиці типів, що стовпець date має тип time, а price — numeric. Якщо date розпізнано як text, перевірте формат дати у файлі.

Крок 2. Перетворення на часовий ряд

- Віджет As Timeseries. У полі Time variable оберіть date.
- Вхід: Data з віджета File. Вихід: Time series.

Крок 3. Заповнення пропуску

- Віджет Interpolate. Оберіть тип інтерполяції, який відповідає обраному вами у завданні 2.
- Порівняйте значення за серпень 2017 з тим, що ви отримали в Python: вони мають збігтися.

Крок 4. Розвідувальні віджети

- Line Chart — графік ряду; зіставте з графіком із завдання 3.
- Correlogram — автокореляція; зіставте значущі лаги з ACF із завдання 5.
- Difference — диференціювання; Seasonal Adjustment — зняття сезонної складової.

Крок 5. Модель

- Віджет ARIMA Model. Встановіть p = 1, d = 1, q = 1.
- Вхід: Time series з віджета Interpolate. Вихід, потрібний далі, — Time series model.

Крок 6. Оцінювання

- Віджет Model Evaluation. До нього підключіть ДВА входи: Time series з Interpolate і Time series model з ARIMA Model.
- Встановіть Number of folds = 7 і Forecast steps = 3.
- УВАГА. За типових налаштувань (20 фолдів) Orange відмовиться рахувати. Це не збій: у віджеті є перевірка n_folds × forecast_steps + лаг ≤ довжина ряду, а 20 × 3 = 60 більше за 46. Поясніть це у звіті.

Що Orange робить усередині Model Evaluation

Для кожного фолду f від 1 до n віджет навчає модель на спостереженнях до позиції −f·steps і прогнозує наступні steps. Це та сама ретроспективна перевірка з рухомим початком, що й у Частині 1, лише фолди перебираються у зворотному порядку. Тому при 7 фолдах по 3 кроки перевіряються ті самі 21 останній місяць.

6. Головне завдання роботи: чому числа не збігаються

Orange і statsmodels використовують один і той самий обчислювальний двигун: віджет ARIMA Model є обгорткою над statsmodels.tsa.arima.model.ARIMA. При однаковому порядку моделі, однакових даних та однакових фолдах прогнози збігаються до знака. Отже, уся розбіжність у метриках походить виключно з їхніх означень.

Формули Orange відкриті: файл functions.py додатка Timeseries.

Метрика	Що рахує Orange	Що зазвичай позначають цією назвою	Наслідок
RMSE	sqrt(Σe^2 / n)	те саме	збігається повністю
MAE	median |e|	mean |e|	різні величини; для несиметричних похибок відрізняються в рази
MAPE	mean|e| / mean|y|	mean |e / y| · 100 %	інша формула; до того ж результат є часткою, а не відсотком
POCID	100 · частка пар із збігом напрямку зміни	у scikit-learn відсутня	вимірює напрямок, а не величину похибки

У завданні 14 ви маєте відтворити кожне з чотирьох чисел Orange у Python за наведеними формулами і переконатися, що ваш розрахунок збігається з таблицею Orange до третього знака. Висновок на кшталт «метрики різні, бо середовища різні» не зараховується.

7. Вимоги до звіту

- Зошит «ЛР4_Прізвище_Варіант.ipynb» із кодом, графіками та письмовими висновками до кожного завдання.
- Файл «ряд_для_orange.csv».
- Файл потоку «потік_orange.ows».
- Знімки екрана з Orange для завдань 11–13.

Зошит має виконуватися від початку до кінця командою Restart & Run All без помилок. Кожне число супроводжується висновком словами: робота з графіками й таблицями, але без письмових відповідей на поставлені питання, вважається невиконаною.

8. Критерії оцінювання

Бали	Умова
0	Ряд не розкладено або прогноз не побудовано. Робота не зарахована.
2	Виконано лише Частину 1: ряд розкладено й прогноз побудовано, але в Orange аналіз не відтворено.
3	Виконано обидві частини, проте прогноз не зіставлено з наївним базисом, а розбіжність результатів двох середовищ не пояснено.
4	Ряд розкладено на складові; прогноз зіставлено з наївним базисом за ретроспективною перевіркою з рухомим початком; той самий аналіз відтворено в Orange; зіставлено результати двох середовищ і пояснено розбіжність метрик.

Бали знімаються за: графіки без пояснення вибору геометрії та шкали; числа без письмового висновку; прогноз без порівняння з базисом; кількість фолдів, відмінну від заданої.

9. Використання штучного інтелекту

Користуватися інструментами штучного інтелекту під час виконання цієї роботи дозволено. Умова одна: ви маєте розуміти кожен рядок зданого коду й кожне написане твердження та бути готовим пояснити їх на захисті.

Декларацію про використання ШІ наведено в кінці зошита із завданнями; вона є обов'язковою частиною звіту. Робота без заповненої декларації не приймається. Якщо ШІ не використовувався, так і зазначте.

Зверніть увагу: завдання 9, 13, 14 і 15 перевіряють те, чого інструмент не зробить за вас, — рецензування чужого аналізу, запуск Orange та пояснення розбіжності між конкретними числами, отриманими саме на вашому варіанті.

10. Типові помилки

- Кількість фолдів у Частині 1 не збігається із заданою в Orange — числа стають незіставними за побудовою.
- Переплутано напрямок висновку тесту ADF: велике p означає нестаціонарність, а не навпаки.
- Висновок про наявність сезонності зроблено без обчислення F_S, лише з того, що STL повернув сезонну складову.
- Прогноз подано без порівняння з наївним базисом.
- Дату збережено у форматі, який Orange не розпізнає як time.
- MAPE пораховано лише на останньому фолді, а не на всіх фолдах разом.
- Аномалії шукано у вихідному ряді, а не в залишках після зняття тренду й сезонності.

11. Рекомендована література

- Hyndman R. J., Athanasopoulos G. Forecasting: Principles and Practice. 3rd ed. OTexts, 2021. Вільний доступ: otexts.com/fpp3 (розділи 3, 5, 8, 9).
- Wilke C. O. Fundamentals of Data Visualization. O'Reilly, 2019. Вільний доступ: clauswilke.com/dataviz.
- Cleveland R. B. та ін. STL: A Seasonal-Trend Decomposition Procedure Based on Loess. Journal of Official Statistics, 1990, vol. 6, no. 1.
- Документація додатка Orange3-Timeseries: orange3-timeseries.readthedocs.io.